

VIME: Self- and Semi-supervised Learning for Tabular Data

项目概述

本项目基于论文 VIME: Extending the Success of Self- and Semi-supervised Learning to Tabular Domain (NeurIPS 2020), 使用现代 PyTorch 2.x 重新实现了 VIME 框架。

在原有 VIME 框架基础上, 新增了 DAE (Denoising Autoencoder) 基线用于对比:

方法	描述	训练任务
Supervised	纯监督学习基线	直接用标注数据训练分类器
DAE	去噪自编码器预训练	无损重构: $\text{clean} \rightarrow \text{clean}$
VIME-Self	VIME 自监督预训练	去噪 + mask 预测: $\text{corrupted} \rightarrow \text{clean} + \text{mask}$
VIME	VIME 半监督学习	VIME-Self + 伪标签一致性正则化

关键区别: - **DAE:** 只用重构损失, 无 mask 预测任务 - **VIME-Self:** 重构损失 + mask 预测损失 (需要学习识别哪些特征被打乱)

为了更好地理解 VIME 的工作机制, 我创建了一个可控的合成数据集生成器:

生成过程:

```
潜变量  $z$  (10维)  $\sim N(0,1)$ 
↓
有用特征  $x_{\text{informative}} = \text{min-max}(z @ W_x + \text{noise})$  [连续值, [0,1]]
↓
噪声特征  $x_{\text{noise}} \sim U(0,1)$  [与y无关的随机噪声]
↓
最终特征  $x = [x_{\text{informative}}, x_{\text{noise}}]$  [固定200维]
↓
标签  $y$  (10类) =  $\text{softmax}(z @ W_y + \text{noise})$ 
```

关键特性: - 总特征维度固定为 200 - $n_{\text{noise_features}}$ 控制噪声特征数量 - 有用特征数 = $200 - n_{\text{noise_features}}$

实验结果

实验设置

- ****标注样本数**:** 500 (所有实验统一)
- ****迭代次数**:** 10次 (报告均值 \pm 标准差)
- ****随机种子**:** 42-51 (每次迭代不同seed保证可重复性)
- ****默认参数**:** ``p_m=0.3`, `alpha=2.0`, `K=3`, `beta=1.0`` (MNIST) 或 ``beta=0.1`` (合成数据)

合成数据实验结果

****运行命令**:**

```
``bash
```

```
# 无噪声特征 (0% 无关变量比例, 200个有用特征)
```

```
python train.py --dataset synthetic --n_noise_features 0
```

```
# 50个噪声特征 (25% 无关变量比例, 150个有用特征)
```

```
python train.py --dataset synthetic --n_noise_features 50
```

```
# 100个噪声特征 (50% 无关变量比例, 100个有用特征)
```

```
python train.py --dataset synthetic --n_noise_features 100
```

无关变量比例	方法	准确率 (Mean \pm Std)	vs Baseline
0%	Supervised	0.7199 \pm 0.0251	-
	DAE	0.7656 \pm 0.0044	+6.3%
	VIME-Self	0.7647 \pm 0.0064	+6.2%
	VIME	0.7553 \pm 0.0054	+4.9%
25%	Supervised	0.6921 \pm 0.0112	-
	DAE	0.7039 \pm 0.0108	+1.7%
	VIME-Self	0.7306 \pm 0.0067	+5.6%
	VIME	0.7582 \pm 0.0038	+9.6%
50%	Supervised	0.5514 \pm 0.0142	-
	DAE	0.5741 \pm 0.0100	+4.1%
	VIME-Self	0.6280 \pm 0.0071	+13.9%
	VIME	0.6793 \pm 0.0060	+23.2%

代码架构

VIME/

train.py	# 主训练脚本
data.py	# MNIST数据加载
synthetic_data.py	# 合成数据生成器 (新增)
autoencoder.py	# Autoencoder实现 (新增)
self_supervised.py	# VIME-Self实现
semi_supervised.py	# VIME半监督实现
baselines.py	# 监督学习基线 (MLP, Logit, XGBoost)
utils.py	# 工具函数 (mask生成、评估指标)

使用方法

安装依赖

```
python -m venv venv
source venv/bin/activate # Windows: venv\Scripts\activate
pip install -r requirements.txt
```

运行实验

MNIST 数据集:

```
python train.py --dataset mnist --iterations 10 --label_no 500 --seed 42
```

合成数据 (无噪声):

```
python train.py --dataset synthetic --n_noise_features 0
```

合成数据 (50 个噪声特征, 25% 无关变量比例):

```
python train.py --dataset synthetic --n_noise_features 50
```

合成数据 (100 个噪声特征, 50% 无关变量比例):

```
python train.py --dataset synthetic --n_noise_features 100
```

主要参数

参数	说明	默认值
--dataset	数据集选择 (mnist/synthetic)	synthetic

参数	说明	默认值
--iterations	实验重复次数	10
--label_no	标注样本数量	1000
--p_m	Corruption 概率	0.3
--alpha	特征损失权重	2.0
--K	增强样本数量	3
--beta	半监督损失权重	1.0
--n_noise_features	噪声特征数 (仅合成数据)	0
--seed	随机种子	42

技术细节

为了与原始 Keras 实现保持一致, 使用相同的 RMSprop 参数:

```
optimizer = torch.optim.RMSprop(
    model.parameters(),
    lr=0.001,      # Keras default
    alpha=0.9,     # Keras default (rho)
    eps=1e-7       # Keras default
)
```

致谢

本项目基于以下论文和代码:

```
@inproceedings{yoon2020vime,
  title={VIME: Extending the Success of Self-and Semi-supervised Learning to Tabular Domain},
  author={Yoon, Jinsung and Zhang, Yao and Jordon, James and Van Der Schaar, Mihaela},
  booktitle={Advances in Neural Information Processing Systems},
  volume={33},
  year={2020}
}
```

License

本项目基于原始 VIME 代码改编, 遵循相同的开源协议。